

T.C. İSTANBUL ÜNİVERSİTESİ

FEN FAKÜLTESİ

BİLGİSAYAR BİLİMLERİ BÖLÜMÜ

YAPAY ZEKA DERSİ

ARAŞTIRMA ÖDEVİ

KREDİ KARTI SAHTEKÂRLIĞI TESPİTİNDE
MAKİNE ÖĞRENMESİ TABANLI ANOMALİ TESPİT
MODELLERİNİN

KURAL TABANLI SİSTEMLERE KARŞI
KARŞILAŞTIRILMASI

Hazırlayan: Zehra Öztürk

Öğrenci No: 0414230008

Tarih: Mayıs 2026

1. Giriş

Günümüzde dijitalleşmenin hızlanmasıyla birlikte; elektronik ödeme sistemleri, günlük ticaretin ayrılmaz bir unsuru haline gelmiştir. Kredi kartı kullanımlarındaki hızlı artış, dolandırıcılık faaliyetlerini de beraberinde getirerek küresel ölçekte büyük ekonomik zararlara yol açmıştır. Nilson Report (2023) verilerine göre, kredi kartı sahtekarlığından kaynaklanan küresel kayıpların 2027 yılına kadar yılda 40 milyar doları geçmesi öngörülmektedir. Bu veriler, sahtekarlık tespitinin sadece teknik bir konu değil, aynı zamanda mali istikrar ve tüketici güveni bakımından da kritik bir sorun olduğunu göstermektedir.

Geleneksel sahtekarlık tespit yöntemleri, büyük ölçüde kural tabanlı sistemlere dayanmaktadır. Bu sistemler, "belirli bir bölgeden gerçekleştirilen işlem şüphelidir" veya "günlük harcama limitini aşan işlemler engellensin" gibi daha önceden tanımlanmış eşik değerlere göre işlem yapmaktadır. Bu yöntem bilinen dolandırıcılık yöntemlerine karşı etkili olsa da yeni ve karmaşık saldırı yöntemlerine karşı yetersiz kalmaktadır. Sahtekarlık yöntemleri sürekli olarak değişir ve gelişirken, statik kurallar güncellenmediğinde sistemin tespit yeteneği zamanla azalmaktadır.

Makine öğrenmesi tabanlı anomali tespit modelleri, bu sınırlılıklara karşı bir çözüm olarak tasarlanmıştır ve son dönemlerde finansal güvenlik alanında artan bir ilgiyle karşılaşmaktadır. Random Forest, XGBoost ve derin öğrenme gibi algoritmalar; geçmiş verilerden örüntüler çıkararak dinamik karar sınırları geliştirmekte ve böylece daha önce tanımlanmamış sahtekarlık davranışlarını da tespit edebilmektedir. Bu modellerin kural tabanlı sistemlerle karşılaştırıldığında sunduğu doğruluk, duyarlılık ve uyarlanabilirlik yönündeki avantajlar, akademik literatürde detaylı olarak ele alınmaya başlanmıştır.

Bu çalışma, kredi kartı dolandırıcılığı tespitinde makine öğrenmesine dayalı anomali tespit modellerinin geleneksel kural tabanlı sistemlere kıyasla doğruluk, duyarlılık ve uyarlanabilirlik açısından sunduğu ölçülebilir avantajları incelemeyi amaçlamaktadır. Bu çerçevede, kamuya açık bir kredi kartı işlem veri seti üzerinde hem kural tabanlı bir referans sistem hem de makine öğrenmesi modelleri uygulanacak; elde edilen sonuçlar Precision, Recall, F1-Score ve ROC-AUC metrikleri kullanılarak karşılaştırmalı olarak değerlendirilecektir. Çalışmanın, sahtekarlık tespit sistemlerinin geliştirilmesine dair pratik öneriler sunması ve bu alandaki akademik literatüre katkıda bulunması beklenmektedir.

2. Literatür Taraması

2.1. Dornadula ve Geetha (2019)

Dornadula ve Geetha (2019), Avrupa kredi kartı sahtekarlık veri seti üzerinde makine öğrenmesi algoritmalarının sahtekarlık tespitindeki etkinliğini karşılaştırmalı olarak incelemiştir. Çalışmada kart sahiplerinin işlem tutarlarına göre kümelere ayrıldığı ve her küme için ayrı sınıflandırıcıların eğitildiği kayan pencere (sliding window) tabanlı bir yöntem önerilmiştir. Araştırmacılar, veri setinin yalnızca %0,172 oranında sahte işlem içermesi nedeniyle belirgin bir sınıf dengesizliği (class imbalance) sorunuyla karşılaşmış; bu sorunu aşmak için SMOTE (Sentetik Azınlık Örnekleme Tekniği) uygulamış ve Mathews Korelasyon Katsayısı (MCC) gibi dengesiz veri setlerine uygun değerlendirme metrikleri kullanmıştır. Bulgular, SMOTE uygulanmış veri seti üzerinde Random Forest algoritmasının 0,9996 MCC değeriyle en yüksek performansı sergilediğini ortaya koymuştur. Çalışmanın önemli bir katkısı, sahtekarlık örüntülerinin zaman içinde değişmesini ifade eden kavram kayması (concept drift) sorununa yönelik geribildirim mekanizması önerisidir.

Bununla birlikte, çalışma gerçek zamanlı akış verileri üzerinde sınırlı ölçekte test edilmiş olup üretim ortamlarındaki uygulanabilirliği henüz yeterince araştırılmamıştır. Yine de bu çalışma, kural tabanlı sistemlerin statik yapısına kıyasla makine öğrenmesinin değişen saldırı örüntülerine uyum sağlama kapasitesini somut biçimde ortaya koymaktadır.

[1]Dornadula, V. N., & Geetha, S. (2019). *Credit card fraud detection using machine learning algorithms. Procedia Computer Science*, 165, 631–641.

2.2. Perols (2011)

Perols (2011), finansal tablo sahtekârlığının tespitinde lojistik regresyon, destek vektör makineleri (SVM), yapay sinir ağları (ANN), karar ağaçları ve topluluk yöntemleri (bagging, stacking) dahil olmak üzere altı farklı istatistiksel ve makine öğrenmesi modelini kapsamlı biçimde karşılaştırmıştır. Çalışmanın temel katkısı, sınıf dengesizliği ve yanlış sınıflandırma maliyetleri gibi sahtekârlık alanına özgü karakteristiklerin model değerlendirmesine sistematik biçimde dahil edilmesidir. Bulgular, genel kanının aksine, lojistik regresyon ve SVM'nin sinir ağlarına kıyasla daha tutarlı ve üstün performans sergilediğini göstermiştir. Perols (2011), bu durumu lojistik regresyonun sinyal-gürültü ayrımının güç olduğu ortamlarda daha doğru olasılık tahminleri üretmesine bağlamaktadır. Çalışma aynı zamanda 42 öngörücü değişken arasından yalnızca altısının — denetçi değişimi, toplam ihtiyari tahakkuklar, Büyük 4 denetçi, alacak hesapları, analist tahminlerini karşılama ve beklenmedik çalışan verimliliği — farklı modeller tarafından tutarlı biçimde seçildiğini saptamıştır. Bu bulgu, kredi kartı sahtekârlık tespitindeki özellik seçimi tartışmaları açısından da doğrudan yol gösterici niteliktedir. Çalışmanın sınırlılığı, ön işleme ve model değerlendirmesinde aynı veri setinin kullanılmış olmasıdır; bu durum sonuçların genellenebilirliğini kısmen kısıtlamaktadır.

[2] Perols, J. (2011). *Financial statement fraud detection: An analysis of statistical and machine learning algorithms. Auditing: A Journal of Practice & Theory*, 30(2), 19–50.

2.3. Happa vd. (2019)

Happa ve diğerleri (2019), siber güvenlik alanında anomali tespitine yönelik geleneksel veri görselleştirme yaklaşımlarının ötesine geçen Pattern-of-Life görsel metafor yöntemini önermiştir. Çalışmada ağ bağlantıları, CPU kullanımı ve dosya sistemi aktiviteleri gibi ham sistem verileri; şehir manzarası ve galaksi kümesi gibi soyut görsel ortamlara dönüştürülmüş, analistlerin bu ortamlar aracılığıyla anomali tespit edip edemeyeceği incelenmiştir. Üç katılımcıyla yürütülen ön çalışma, genel yaklaşımın uygulanabilirliğini doğrulamakla birlikte yanlış pozitif oranları ve metafor eşleştirme stratejilerinin optimize edilmesi gerektiğini de ortaya koymuştur. Bu çalışma, kural tabanlı sistemlerin belirli imzalara dayalı çalışması ve sıfırıncı gün saldırıları gibi bilinmeyen tehditlere karşı yetersiz kalmasına karşın, anomali tabanlı yaklaşımların normal davranış örüntülerinden sapmaları tespit edebildiğini vurgulayarak mevcut çalışmayla doğrudan bağlantı kurmaktadır. Yöntemin en önemli sınırlılığı, laboratuvar koşullarında yürütülmüş küçük ölçekli bir fizibilite çalışması niteliği taşıması ve büyük ölçekli gerçek dünya ortamlarındaki performansının henüz bilinmemesidir.

[3] Happa, J., Bashford-Rogers, T., Agrafiotis, I., Goldsmith, M., & Creese, S. (2019). *Anomaly detection using pattern-of-life visual metaphors. IEEE Access*, 4.

2.4. Phua vd. (2010)

Phua ve diğerleri (2010), son on yılda yayımlanan veri madenciliği tabanlı sahtekârlık tespit çalışmalarını kapsamlı biçimde derleyen bir derleme çalışması sunmuştur. Çalışma; sahtekârlık türlerini sistematik olarak sınıflandırmış, etkilenen sektörleri (kredi kartı, sigorta, telekomünikasyon, iç sahtekârlık) tanımlamış ve bu alanlarda kullanılan denetimli, yarı denetimli ile denetimsiz yaklaşımları karşılaştırmalı olarak değerlendirmiştir. Yazarlar, sahtekârlık tespitindeki iki temel eleştiriyi açıkça dile getirmektedir: kamuya açık gerçek veri setlerinin yetersizliği ve iyi belgelenmiş yöntemlerin azlığı. Bu bağlamda, gerçek veriye erişimin kısıtlı olduğu durumlarda sentetik veri üretiminin gerekçesi ve yöntemi ayrıntılı biçimde ele alınmıştır. Çalışma aynı zamanda, sahtekârlık tespitinin yalnızca teknik bir sınıflandırma problemi olmadığını; operasyonel gereksinimler, kaynak kısıtları ve kavram kayması (concept drift) gibi pratik faktörlerin model seçimini belirleyici ölçüde etkilediğini vurgulamaktadır. Kredi kartı sahtekârlığında dengesiz sınıf dağılımı sorununun ele alınış biçimleri açısından mevcut çalışmayla doğrudan bağlantı kurmaktadır. Çalışmanın temel sınırlılığı, teknik yöntemlerin uygulamalı karşılaştırmasından ziyade bir literatür taraması niteliği taşımasıdır; bu durum spesifik performans iddialarının doğrulanmasını güçleştirmektedir.

[4] Phua, C., Lee, V., Smith, K., & Gayler, R. (2010). *A comprehensive survey of data mining-based fraud detection research*. *arXiv preprint arXiv:1009.6119*.

2.5. Bolton ve Hand (2002)

Bolton ve Hand (2002), istatistiksel sahtekârlık tespiti yöntemlerini çeşitli uygulama alanları üzerinden sistematik biçimde inceleyen kapsamlı bir derleme çalışması sunmuştur. Çalışma, denetimli ve denetimsiz yaklaşımlar arasındaki temel ayrımı netleştirmiş; denetimli yöntemlerin bilinen sahtekârlık örüntülerini tanımlamadaki etkinliğini, denetimsiz yöntemlerin ise daha önce karşılaşılmamış anormallikleri tespit etmedeki rolünü açıklamıştır. Yazarlar, sahtekârlık tespitindeki en kritik metodolojik sorunlardan birini açıkça ortaya koymuştur: dengesiz sınıf dağılımı nedeniyle basit doğruluk metriğinin yanıltıcı olduğu ve maliyet ağırlıklı performans ölçütlerinin kullanılması gerektiği. Bolton ve Hand (2002), aynı zamanda Akran Grubu Analizi (Peer Group Analysis) ve Kırılma Noktası Analizi (Break Point Analysis) gibi davranış profillemeye yöntemlerini kredi kartı sahtekârlığına uygulamış, bu yöntemlerin zaman içinde hesap davranışını izlemek ve bireysel hesap düzeyinde anomali tespit etmek için nasıl kullanılabileceğini göstermiştir. Çalışma, sahtekârlık tespitinin sürekli evrim geçiren bir disiplin olduğunu ve sahtekârlık yöntemleri değiştikçe tespit modellerinin de buna ayak uydurması gerektiğini vurgulayan uyarlanabilirlik (adaptability) ilkesini de teorik çerçeveye dahil etmektedir. Bu bağlamda mevcut çalışmanın teorik temellerinden birini oluşturmakta ve kural tabanlı sistemlerin statik yapısına karşı makine öğrenmesinin uyarlanabilir üstünlüğünü tartışmak için sağlam bir zemin sunmaktadır.

[5] Bolton, R. J., & Hand, D. J. (2002). *Statistical fraud detection: A review*. *Statistical Science*, 17(3), 235–255.

3. Teorik Çerçeve

3.1. Kural Tabanlı Sistemler ve Sınırlılıkları

Geleneksel sahtekârlık tespit sistemleri, önceden tanımlanmış eşik değerlere ve mantıksal kurallara dayanan deterministik yapılar üzerine inşa edilmiştir. Bu sistemlerde bir işlemin şüpheli

sayılıp sayılmayacağı, "işlem tutarı X değerini aşıyorsa engelle" veya "aynı kartla 10 dakika içinde farklı ülkelerden işlem yapılıyorsa uyar" gibi sabit koşullarla belirlenmektedir. Kural tabanlı yaklaşımın temel sorunu, yalnızca daha önce tanımlanmış sahtekârlık kalıplarını tespit edebilmesidir. Sahtekârlık yöntemleri zaman içinde evrildiğinde — örneğin küçük tutarlı çok sayıda işlem yapılarak eşik değerlerin altında kalındığında — sistem bu yeni örüntüleri tanıyamaz. Bolton ve Hand (2002), bu durumu sahtekârlık tespitinin sürekli evrim geçiren bir disiplin olduğu şeklinde nitelendirmiş ve statik kuralların değişen sahtekârlık davranışlarına karşı zamanla etkinliğini yitireceğini vurgulamıştır.

3.2. Makine Öğrenmesi ile Dinamik Karar Sınırları ve Confusion Matrix

Makine öğrenmesi tabanlı modeller, sabit kurallar yerine tarihsel verilerden örüntüler öğrenerek dinamik karar sınırları oluşturur. Bu yaklaşımda model, eğitim aşamasında sahte ve gerçek işlemlerin özelliklerini istatistiksel olarak öğrenir; test aşamasında ise yeni işlemleri bu öğrenilmiş sınırlara göre sınıflandırır. Model performansını değerlendirmek için Confusion Matrix analizi kullanılır. Confusion Matrix, bir sınıflandırıcının yaptığı dört temel karar türünü görselleştirir: gerçek işlemi doğru sınıflandırma (True Negative, TN), sahte işlemi doğru tespit etme (True Positive, TP), gerçek işlemi yanlışlıkla sahte sayma (False Positive, FP) ve sahte işlemi gözden kaçırma (False Negative, FN). Bu matris üzerinden türetilen temel performans metrikleri şu şekilde formüle edilmektedir:

$$Precision = \frac{TP}{TP + FP}$$
$$Recall = \frac{TP}{TP + FN}$$
$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Kredi kartı sahtekârlığı bağlamında en kritik hata türü False Negative'dir: modelin sahte bir işlemi gözden kaırması hem doğrudan mali kayba hem de müşteri güveninin zedelenmesine yol açar. Bu nedenle yalnızca genel doğruluğu (accuracy) maksimize etmek yanıltıcı olabilir; Phua vd. (2010) bu durumu açıkça ortaya koymuş ve maliyet ağırlıklı performans ölçütlerinin kullanılması gerektiğini vurgulamıştır. ROC-AUC metriği ise modelin farklı eşik değerlerindeki genel ayırım gücünü ölçerek tek bir skaler değerle ifade eder; bu sayede kural tabanlı sistem ile makine öğrenmesi modelinin karşılaştırmalı değerlendirmesi mümkün hale gelir.

3.3. Random Forest Algoritması

Random Forest, birden fazla karar ağacının bir araya getirilmesiyle oluşturulan bir topluluk öğrenme (ensemble learning) yöntemidir. Her karar ağacı, eğitim verisinin rastgele örneklenmiş bir alt kümesi üzerinde bağımsız olarak eğitilir; nihai sınıflandırma kararı ise bu ağaçların çoğunluk oylamasıyla (majority voting) belirlenir. Tek bir karar ağacına kıyasla Random Forest, aşırı öğrenme (overfitting) eğilimini azaltır ve veri gürültüsüne karşı daha dayanıklıdır. Kredi kartı sahtekârlığı veri setlerinde yaygın olarak karşılaşılan dengesiz sınıf dağılımı (class imbalance) sorununda — sahte işlemlerin tüm veri setinin yalnızca küçük bir bölümünü oluşturduğu durumlarda — Random Forest, her ağacı farklı örneklem üzerinde eğittiği için azınlık sınıfını (sahte işlemler) daha iyi öğrenebilmektedir. Dornadula ve Geetha (2019), aynı Avrupa kredi kartı veri seti üzerinde Random Forest'ın SMOTE uygulamasıyla birlikte 0,9996 MCC değerine ulaştığını göstermiş; bu bulgu algoritmanın dengesiz veri koşullarındaki üstün başarımını doğrulamaktadır.

3.4. Pattern of Life Yaklaşımı


Pattern of Life yaklaşımı, her kart sahibinin bireysel işlem davranışını zaman içinde modelleyen ve bu profilden sapmaları anormallik olarak tanımlayan bir tespit stratejisidir. Bu yaklaşıma göre bir işlemin şüpheli sayılması için mutlak bir eşik değeri aşması gerekmez; kart sahibinin kendi geçmiş davranışından anlamlı ölçüde sapması yeterlidir. Örneğin, düzenli olarak küçük tutarlı alışveriş yapan bir kart sahibinin hesabından ani büyük işlemler gerçekleşmesi, kural tabanlı sistemde herhangi bir eşik aşmasa dahi Pattern of Life modelinde yüksek şüphe skoru üretebilir. Bolton ve Hand (2002) bu yaklaşımı Akran Grubu Analizi (Peer Group Analysis) çerçevesinde formüle etmiş; bir hesabın davranışının benzer hesaplardan oluşan akran grubuyla karşılaştırılmasını ve t-istatistiği ile standardize edilmiş sapma skorunun hesaplanmasını önermiştir. Bu çalışmada Random Forest modeline dahil edilecek davranışsal özellikler (işlem sıklığı, ortalama tutar, işlem saati dağılımı gibi değişkenler) bu teorik çerçeveden türetilmektedir.

4. Metodoloji

4.1. Veri Seti

Bu çalışmada, Avrupa'da faaliyet gösteren kredi kartı sahiplerinin Eylül 2013'te gerçekleştirdiği işlemleri içeren ve Machine Learning Group - ULB tarafından kamuya açık olarak sunulan Kaggle Credit Card Fraud Detection veri seti kullanılmıştır. Veri seti toplam 284.807 işlemten oluşmakta olup bunların yalnızca 492'si (%0,173) sahte işlem niteliği taşımaktadır. Bu durum, veri setinin belirgin bir sınıf dengesizliği (class imbalance) içerdiğini ortaya koymakta ve bu özelliğiyle gerçek dünya finansal işlem verilerini temsil etmektedir. Gizlilik gereklilikleri nedeniyle orijinal özellikler Temel Bileşenler Analizi (PCA) ile dönüştürülmüş; V1'den V28'e kadar isimlendirilen 28 bileşen elde edilmiştir. Dönüştürülmemiş tek değişkenler işlem tutarı (Amount) ve işlem zamanı (Time) olup veri setinde herhangi bir eksik değer bulunmamaktadır. Dornadula ve Geetha (2019) da aynı veri seti üzerinde çalışmış olmakla birlikte, mevcut çalışma farklı bir model mimarisi ve karşılaştırma çerçevesi benimsemektedir.

Şekil 1: Sınıf Dağılımı ve İşlem Tutarı Dağılımı



4.2. Kural Tabanlı Referans Sistem

Makine öğrenmesi modelinin karşılaştırılabileceği bir referans nokta oluşturmak amacıyla basit bir kural tabanlı sistem tasarlanmıştır. Bu sistemde, işlem tutarının tüm veri setinin 75. yüzdelik değerini (77,16 \$) aşması durumunda işlem sahte olarak sınıflandırılmaktadır. Kural tabanlı sistemler gerçek dünya uygulamalarında yaygın olarak kullanılan eşik tabanlı yaklaşımları temsil etmekte olup bu çalışmada söz konusu yaklaşımın sınırlılıklarını ortaya koymak için bilinçli olarak

basit tutulmuştur. Phua vd. (2010), bu tür statik kural sistemlerinin değişen sahtekârlık örüntülerine uyum sağlayamadığını ve yüksek yanlış pozitif oranlarına yol açtığını vurgulamaktadır.

4.3. Random Forest Modeli

Makine öğrenmesi modeli olarak scikit-learn kütüphanesi kullanılarak Random Forest sınıflandırıcısı uygulanmıştır. Model, 100 karar ağacından ($n_estimators=100$) oluşmakta ve sınıf dengesizliğini ele almak amacıyla `class_weight='balanced'` parametresi ile yapılandırılmıştır. Bu parametre, azınlık sınıfına (sahte işlemler) ait örneklerle daha yüksek ağırlık atayarak modelin sahte işlemleri daha etkin biçimde öğrenmesini sağlamaktadır. Veri seti, rastgele tohum değeri 42 (`random_state=42`) kullanılarak %80 eğitim ve %20 test olarak bölünmüştür. Sınıf oranının her iki kümede de korunması amacıyla stratified split yöntemi benimsenmiştir. Eğitim kümesi 227.845 işlem (394 sahte), test kümesi ise 56.962 işlem (98 sahte) içermektedir. Tüm analizler Python programlama dili ile Google Colab ortamında gerçekleştirilmiştir.

4.4. Değerlendirme Metrikleri

Model performansının değerlendirilmesinde genel doğruluk (accuracy) metriği yerine sınıf dengesizliğine duyarlı ölçütler tercih edilmiştir. Bunun temel nedeni, %0,173 sahte işlem oranına sahip bu veri setinde tüm işlemleri meşru olarak sınıflandıran naif bir modelin dahi %99,827 doğruluk elde edebileceği, dolayısıyla bu metriğin yanıltıcı sonuçlar üretebileceğidir. Bu gerekçeyle Precision, Recall, F1-Score ve ROC-AUC metrikleri hesaplanmıştır. Özellikle Recall metriği kritik önem taşımaktadır; zira sahte bir işlemin gözden kaçırılması (False Negative) hem doğrudan mali kayba hem de müşteri güveninin zedelenmesine yol açmaktadır. ROC-AUC değeri ise modelin farklı karar eşiklerindeki genel ayırım gücünü ölçmekte ve iki modelin bütüncül biçimde karşılaştırılmasına olanak tanımaktadır.

Tablo 1: Kural Tabanlı Sistem ve Random Forest Karşılaştırması

Model	Precision	Recall	F1-Score	ROC-AUC	False Positives	False Negatives	True Positives
Rule-Based System	0.0024	0.3537	0.0049	0.5519	71028	318	174
Random Forest	0.9605	0.7449	0.8391	0.9529	3	25	73

**Araştırmanın yazım sürecinde Claude (Anthropic, 2026) yapay zeka aracından yararlanılmıştır. Bu araştırmadan literatür taraması, teorik çerçeve oluşturma, bölüm taslakları ve Python kodu geliştirme aşamalarında destek alınmıştır. Python kodları Google Colab ortamında yazar tarafından adım adım çalıştırılmış, elde edilen sonuçlar bizzat yorumlanmış ve tüm akademik içerik yazar tarafından gözden geçirilerek yeniden ifade edilmiştir.*


5. Senaryo/Veri Analizi

5.1. Kural Tabanlı Sistemin Performans Analizi

Kural tabanlı sistemin değerlendirme sonuçları, eşik tabanlı yaklaşımların kredi kartı sahtekârlığı tespitindeki yetersizliğini açıkça ortaya koymaktadır. 75. yüzdeler tutar eşiğine dayanan bu sistem, test verisi üzerinde 0,0024 Precision, 0,3537 Recall ve 0,0049 F1-Score değerleri üretmiştir.

Confusion Matrix incelendiğinde, sistemin 284.807 işlemin 71.028'ini yanlışlıkla sahte olarak sınıflandırdığı görülmektedir. Bu durum, her gün on binlerce meşru müşteri işleminin gereksiz yere engelleneceği anlamına gelmekte ve hem operasyonel maliyet hem de müşteri deneyimi açısından ciddi sorunlara yol açmaktadır. Öte yandan sistem, 492 sahte işlemin yalnızca 174'ünü doğru tespit edebilmiş; 318 sahte işlemi gözden kaçırmıştır. ROC-AUC değerinin 0,5519 olması, sistemin rastgele bir sınıflandırıcıdan yalnızca marjinal düzeyde üstün olduğunu göstermektedir. Bu bulgular, Bolton ve Hand (2002)'in statik kural sistemlerinin değişen sahtekârlık örüntülerine karşı zamanla etkinliğini yitireceği yönündeki teorik öngörüsünü ampirik olarak doğrulamaktadır.


Şekil 2: Kural Tabanlı Sistem Confusion Matrix



5.2. Random Forest Modelinin Performans Analizi

Random Forest modeli, kural tabanlı sisteme kıyasla tüm performans metriklerinde çarpıcı bir iyileşme sergilemiştir. Model, test kümesinde 0,9605 Precision, 0,7449 Recall, 0,8391 F1-Score ve 0,9529 ROC-AUC değerlerine ulaşmıştır. Confusion Matrix incelendiğinde, 98 sahte işlemin 73'ünün doğru tespit edildiği, yalnızca 3 meşru işlemin yanlışlıkla sahte olarak sınıflandırıldığı görülmektedir. Kural tabanlı sistemin ürettiği 71.028 yanlış pozitif karşılık Random Forest yalnızca 3 yanlış pozitif üretmiştir — bu fark yaklaşık 23.676 kat daha az gereksiz alarm anlamına gelmektedir. ROC eğrisinin sol üst köşeye yakın seyretmesi ve AUC değerinin 0,9529 olması, modelin farklı karar eşiklerinde güçlü bir ayrım kapasitesine sahip olduğunu doğrulamaktadır. Bu bulgular, Dornadula ve Geetha (2019)'nın aynı veri seti üzerinde elde ettiği yüksek performans sonuçlarıyla uyum içindedir.

Şekil 3: Random Forest Confusion Matrix ve ROC Eğrisi




5.3. Karşılaştırmalı Değerlendirme

İki modelin karşılaştırmalı analizi, makine öğrenmesi tabanlı yaklaşımın kural tabanlı sisteme göre doğruluk, duyarlılık ve uyarlanabilirlik açısından ölçülebilir üstünlükler sunduğunu açıkça ortaya koymaktadır. Tablo 1'de sunulan karşılaştırma incelendiğinde, F1-Score'un 0,0049'dan 0,8391'e yükseldiği, yani yaklaşık 171 kat iyileşme sağlandığı görülmektedir. Precision açısından değerlendirildiğinde, kural tabanlı sistemin "sahte" olarak işaretlediği işlemlerin yalnızca binde ikisi gerçekten sahteyken, Random Forest'ta bu oran %96'ya ulaşmaktadır. Recall karşılaştırmasında ise kural tabanlı sistem sahte işlemlerin %35'ini tespit ederken Random Forest bu oranı %74'e çıkarmaktadır. Phua vd. (2010) ve Bolton ve Hand (2002)'in teorik çerçevesinde öngörüldüğü üzere, makine öğrenmesi modelinin veriden dinamik karar sınırları öğrenmesi, sabit eşik kurallarına kıyasla hem çok daha az yanlış alarm üretmesini hem de daha fazla sahte işlemi tespit etmesini mümkün kılmaktadır. (Bkz. Tablo 1: Model Karşılaştırması)

5.4. Özellik Önemi Analizi

Random Forest modelinin özellik önemi analizi, sahtekârlık tespitinde en belirleyici değişkenlerin PCA bileşenleri olduğunu ortaya koymaktadır. V14 (0,1799), V10 (0,1154), V12 (0,0962) ve V4 (0,0956) en yüksek öneme sahip dört bileşen olarak öne çıkmaktadır. İşlem tutarını temsil eden Amount değişkeninin önem skoru ise yalnızca 0,0110 düzeyinde kalmaktadır. Bu bulgu son derece anlamlıdır: kural tabanlı sistemimizin karar kriteri olarak kullandığı işlem tutarı, Random Forest modelinde en az önemli değişkenler arasında yer almaktadır. Bu durum, kural tabanlı yaklaşımın neden bu denli düşük performans sergilediğini açıklamaktadır — sahtekârlık davranışı işlem tutarıyla değil, işlemin gizli yapısal özellikleriyle (PCA bileşenleri) ilişkilidir. Happa vd. (2019)'nin vurguladığı üzere, anomali tespitinde bireysel davranış örüntülerini modelleyen çok boyutlu yaklaşımlar tek değişkenli eşik kurallarından çok daha etkin sonuçlar üretmektedir.

Şekil 4: Random Forest Özellik Önemi Analizi



6. Sonuç ve Tartışma

6.1. Araştırma Sorularına Verilen Yanıtlar

Bu çalışma, kredi kartı sahtekârlık tespitinde makine öğrenmesi tabanlı anomali tespit modellerinin geleneksel kural tabanlı sistemlere kıyasla doğruluk, duyarlılık ve uyarlanabilirlik açısından hangi ölçülebilir avantajlar sunduğunu araştırmayı amaçlamıştır. Elde edilen bulgular bu soruyu net biçimde yanıtlamaktadır: Random Forest modeli, kural tabanlı sisteme kıyasla F1-Score'da 171 kat, Precision'da yaklaşık 400 kat iyileşme sağlamış; yanlış pozitif sayısını 71.028'den yalnızca 3'e indirmiştir. ROC-AUC değerinin 0,9529 düzeyine ulaşması, modelin farklı operasyonel koşullarda da güçlü bir ayırım kapasitesi sergilediğini göstermektedir. Bu bulgular, Perols (2011)'ün finansal sahtekârlık tespitinde makine öğrenmesi modellerinin gerçekçi sınıf ve maliyet dengesizliği koşullarında istatistiksel modellere üstünlük sağladığı yönündeki tespitleriyle uyum içindedir.

6.2. Teorik Katkı ve Literatürle İlişki

Çalışmanın bulguları, mevcut literatürü birkaç açıdan desteklemekte ve genişletmektedir. Bolton ve Hand (2002)'in statik kural sistemlerinin değişen sahtekârlık örüntülerine karşı zamanla etkinliğini yitireceği yönündeki teorik öngörüsü, bu çalışmada ampirik olarak doğrulanmıştır. Özellik önemi analizi ise kural tabanlı sistemin karar kriteri olarak benimsediği işlem tutarının (Amount) Random Forest modelinde en az önemli değişkenler arasında yer aldığını ortaya koymuştur. Bu bulgu, Phua vd. (2010)'nun sahtekârlık tespitinde çok boyutlu örüntü analizi yaklaşımının tek değişkenli eşik kurallarından üstün olduğu yönündeki argümanını güçlendirmektedir. Ayrıca Dornadula ve Geetha (2019) ile elde edilen sonuçların tutarlılığı, Random Forest algoritmasının bu veri seti üzerindeki güvenilirliğini teyit etmektedir.

6.3. Sınırlılıklar

Bu çalışmanın birkaç önemli sınırlılığı bulunmaktadır. Her şeyden önce, kullanılan kural tabanlı sistem gerçek dünya uygulamalarındaki karmaşık kural motorlarını tam olarak temsil etmemekte; yalnızca tek bir eşik kuralına dayanmaktadır. İkinci olarak, veri seti yalnızca iki günlük işlem verisini kapsamakta olup uzun vadeli davranışsal değişimleri ve kavram kaymasını (concept drift) yansıtmamaktadır. Üçüncü olarak, PCA dönüşümü nedeniyle özellikler yorumlanamaz hale gelmiş; bu durum modelin karar mekanizmasının açıklanabilirliğini (explainability) kısıtlamaktadır. Son olarak, SMOTE gibi veri dengeleme teknikleri bu çalışmada uygulanmamıştır; bu tekniklerin Recall değerini daha da artırabileceği öngörülmektedir.

6.4. Gelecek Çalışmalar İçin Öneriler

Gelecek araştırmalar birkaç yönde ilerleyebilir. Birincisi, XGBoost ve derin öğrenme modelleriyle karşılaştırmalı analizin genişletilmesi model seçimi tartışmasına katkı sağlayacaktır. İkincisi, SMOTE ve diğer veri dengeleme tekniklerinin Recall üzerindeki etkisinin sistematik olarak incelenmesi önerilebilir. Üçüncüsü, SHAP (SHapley Additive exPlanations) gibi açıklanabilir yapay zeka araçlarının entegrasyonu, modelin karar mekanizmasını şeffaflaştırarak klinik ve hukuki kabul edilebilirliği artırabilir. Son olarak, gerçek zamanlı akış verileri üzerinde model performansının test edilmesi, bulguların operasyonel ortamlara aktarılabilirliğini güçlendirecektir.

7. Kaynakça

Dornadula, V. N., & Geetha, S. (2019). Credit card fraud detection using machine learning algorithms. *Procedia Computer Science*, 165, 631–641.

Perols, J. (2011). Financial statement fraud detection: An analysis of statistical and machine learning algorithms. *Auditing: A Journal of Practice & Theory*, 30(2), 19–50.

Happa, J., Bashford-Rogers, T., Agrafiotis, I., Goldsmith, M., & Creese, S. (2019). Anomaly detection using pattern-of-life visual metaphors. *IEEE Access*, 4.

Phua, C., Lee, V., Smith, K., & Gayler, R. (2010). A comprehensive survey of data mining-based fraud detection research. *arXiv preprint arXiv:1009.6119*.

Bolton, R. J., & Hand, D. J. (2002). Statistical fraud detection: A review. *Statistical Science*, 17(3), 235–255.

**Yapay Zeka Kullanım Beyanı: Bu çalışmada Claude (Anthropic, 2026) yapay zeka aracından araştırma ve yazım sürecinde destek alınmıştır. Ayrıntılar için bkz. Metodoloji Bölümü.*